Presentación Trabajo Bioinformática

Presentación trabajo final

Ainhoa Cadena
Pedro Benito

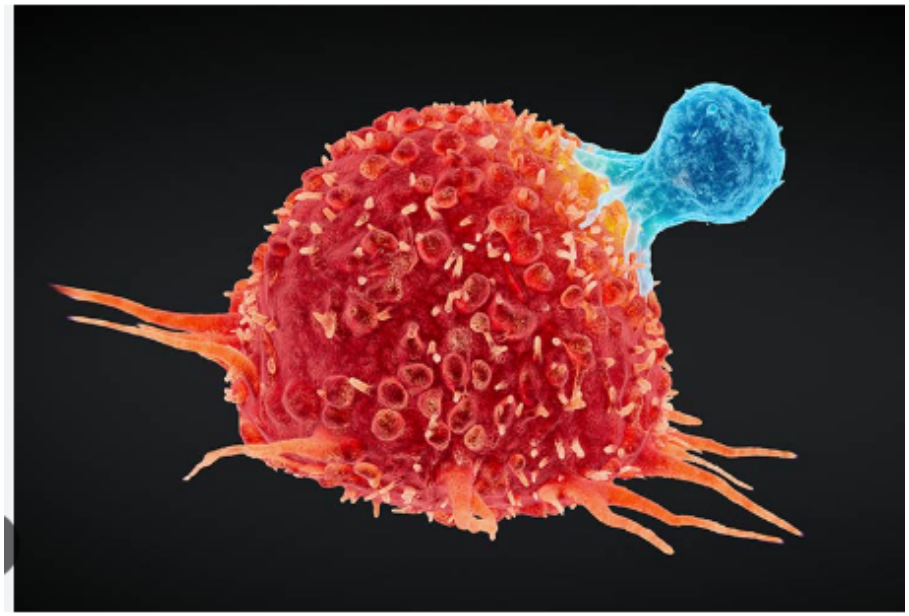
Asignatura de Bioinformática

Indice

1. Introducción: El problema del cáncer
2. Descripción y características
   - Datos de metilación
   - Modelo Híbrido
   - Evaluación del rendimiento
3. Estructura del modelo
   - Codificador
   - Decodificador
   - Clasificador
   - Entrenamiento y prevención de fugas
4. Análisis de resultados
   - Análisis del espacio latente
   - Análisis de la robustez
   - Rendimiento y pruebas
5. Conclusiones
6. Referencias

Introducción: El problema del cáncer

- **Cáncer:** Crecimiento descontrolado de células anormales en el cuerpo
- Puede afectar a gran cantidad de tejidos y órganos
- Una de las principales causas de muerte (16-17 % del total de fallecimientos a nivel mundial.)
- **Conclusión:** Diagnosticar eficiéntemente el cáncer es crucial





Indice

1. Introducción: El problema del cáncer
2. Descripción y características
   - Datos de metilación
   - Modelo Híbrido
   - Evaluación del rendimiento
3. Estructura del modelo
   - Codificador
   - Decodificador
   - Clasificador
   - Entrenamiento y prevención de fugas
4. Análisis de resultados
   - Análisis del espacio latente
   - Análisis de la robustez
   - Rendimiento y pruebas
5. Conclusiones
6. Referencias

CancerNet: descripción y características

- El programa **CancerNet** es un modelo avanzado para el diagnóstico del cáncer.
- El modelo distingue entre 33 tipos de cáncer y determina su tejido de origen.
- Características principales:
  1. Datos de metilación
  2. Modelo Híbrido
  3. Evaluación del rendimiento

CancerNet: a unified deep learning network for pan-cancer diagnostics

Steven Gore & Rajeev K. Azad

Datos de metilación

Metilación del ADN: modificación epigenética que regula la expresión génica sin alterar la secuencia del ADN.

- Se usan datos de metilación de muestras como entrada.
- Datos preprocesados en 24,565 clusters CpG, siguiendo el enfoque de *CancerLocator*.
- Autoencoder variacional (VAE) para aprender representaciones latentes.

Modelo Híbrido

El modelo combina **aprendizaje generativo y clasificación supervisada**.

- VAE para modelar la estructura latente de los datos.
- El espacio latente facilita la separación entre clases.
- Adecuado para datos de **alta dimensión y complejidad**

Evaluación del rendimiento

Se evalúa la capacidad del modelo para clasificar correctamente los tipos de cáncer.

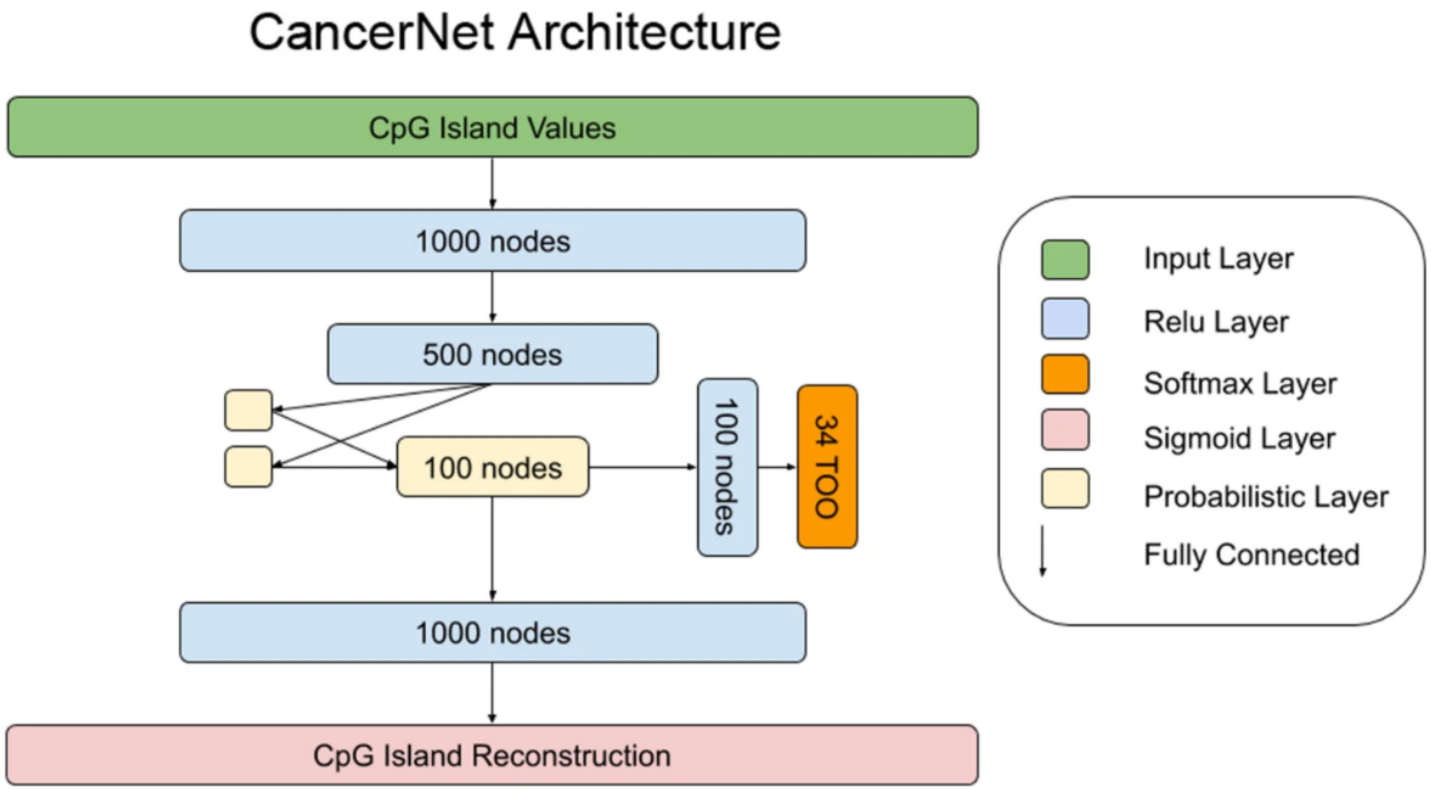
- Datos de repositorios **TCGA y NCBI GEO**.
- Métricas principales: *precisión*, *recall* y *F-medida ponderada*.
- Librería `scikit-learn`, considerando el desequilibrio de clases.

Indice

1. Introducción: El problema del cáncer
2. Descripción y características
   - Datos de metilación
   - Modelo Híbrido
   - Evaluación del rendimiento
3. Estructura del modelo
   - Codificador
   - Decodificador
   - Clasificador
   - Entrenamiento y prevención de fugas
4. Análisis de resultados
   - Análisis del espacio latente
   - Análisis de la robustez
   - Rendimiento y pruebas
5. Conclusiones
6. Referencias

Estructura del modelo

- Implementado en Python usando **Keras** con **TensorFlow**.
- Compuesto por tres módulos principales:
  - **Codificador (Encoder)**
  - **Decodificador (Decoder)**
  - **Clasificador (Classifier)**



Codificador

Capa que procesa los datos originales y extrae una representación comprimida

- **Entrada:** 24,565 nodos.
- Capa densa de 1,000 nodos con activación **ReLU**.
- Dos capas densas sin activación.
- Capa latente probabilística con **100 nodos**.
- Utiliza el VAE para aprender una representación comprimida de los datos.

Decodificador

Capa que reconstruye los datos originales a partir de la representación comprimida del codificador

- Capa densa de **1,000 nodos** con activación **ReLU**.
- Capa de salida de **24,565 nodos** con activación **sigmoide**.

Clasificador

Capa que predice el tipo de cáncer y el tejido de origen a partir de la información compactada del VAE.

- Entrada: **capa latente** (100 nodos).
- Capa intermedia de **100 nodos** con activación **ReLU**.
- Capa de salida de **34 nodos** con activación **softmax**.

Entrenamiento y prevención de fugas

- **Optimizador:** Adam con tasa de aprendizaje **0.001**.
- **Técnica:** *Early stopping* para evitar sobreajuste.
- **Función de pérdida:** Suma de:
  - Pérdida del **VAE**.
  - **Entropía cruzada** para clasificación.
- **Prevención de fuga de información:**
  - Normalización de valores beta sin mezclar información entre muestras.
  - Validación con datos independientes del repositorio *GEO*.

Indice

1. Introducción: El problema del cáncer
2. Descripción y características
   - Datos de metilación
   - Modelo Híbrido
   - Evaluación del rendimiento
3. Estructura del modelo
   - Codificador
   - Decodificador
   - Clasificador
   - Entrenamiento y prevención de fugas
4. Análisis de resultados
   - Análisis del espacio latente
   - Análisis de la robustez
   - Rendimiento y pruebas
5. Conclusiones
6. Referencias

Análisis de los resultados

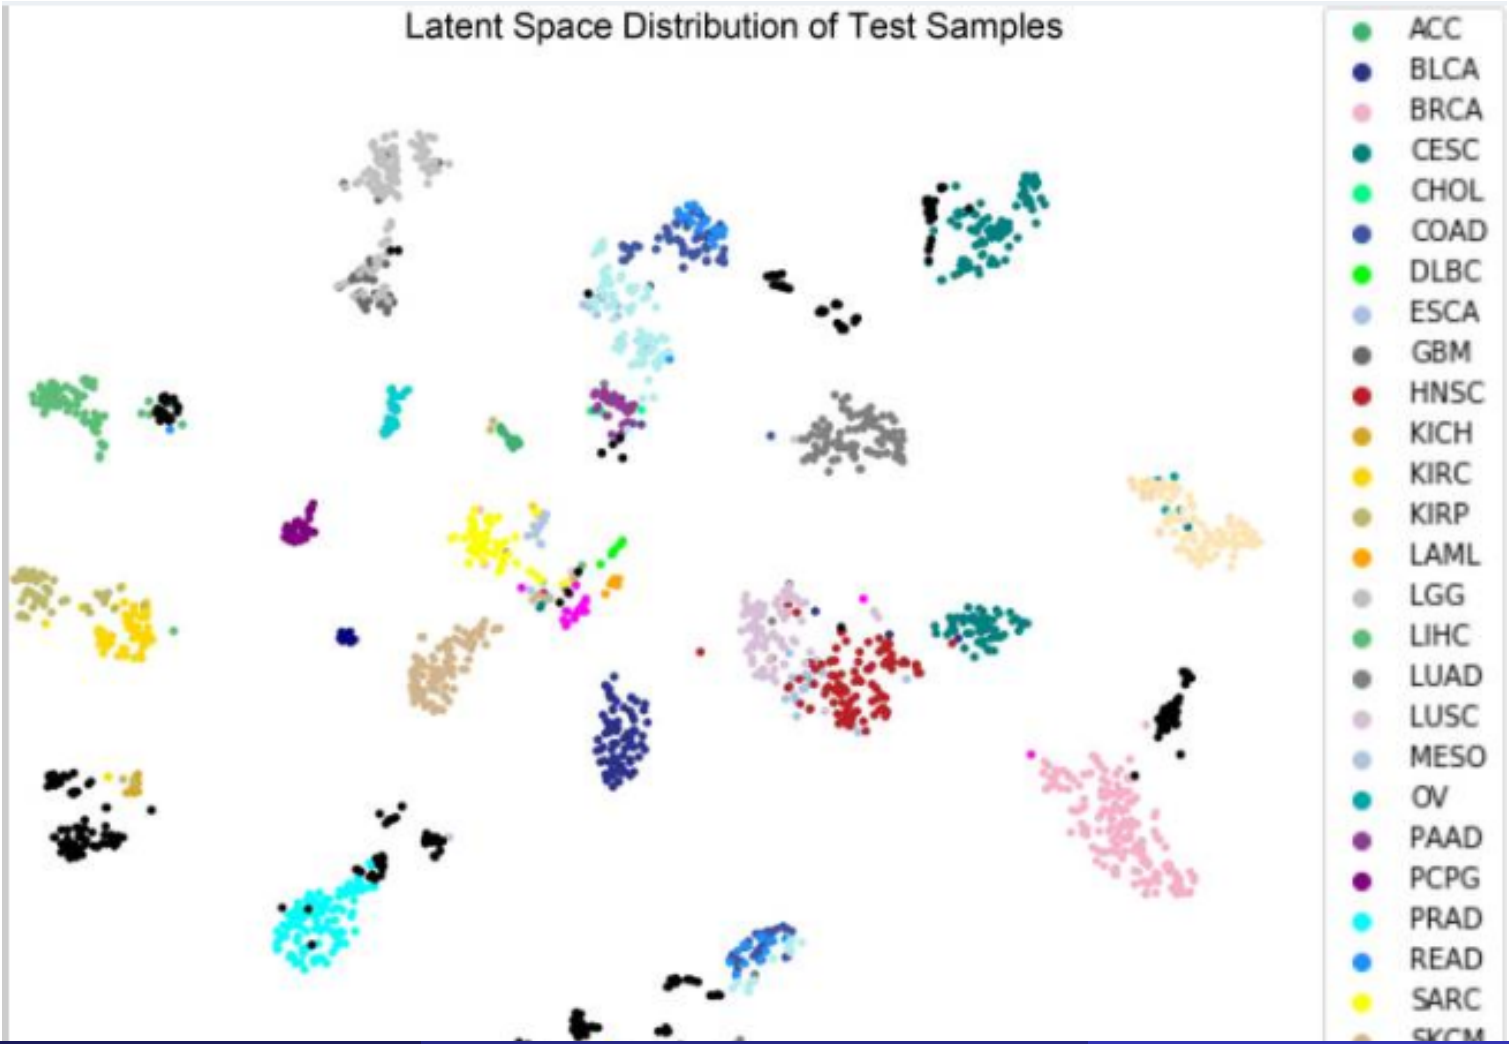
Objetivo: evaluar la representación interna y el comportamiento del modelo en distintos escenarios.

- Análisis del espacio latente.
- Evaluación de la robustez.
- Medición del rendimiento.

Análisis del espacio latente

El modelo clasifica y distribuye las clases en el espacio según proximidad.

- Errores concentrados en clases similares o muestras atípicas.
- Agrupación clara por tejido de origen y subtipo tumoral.



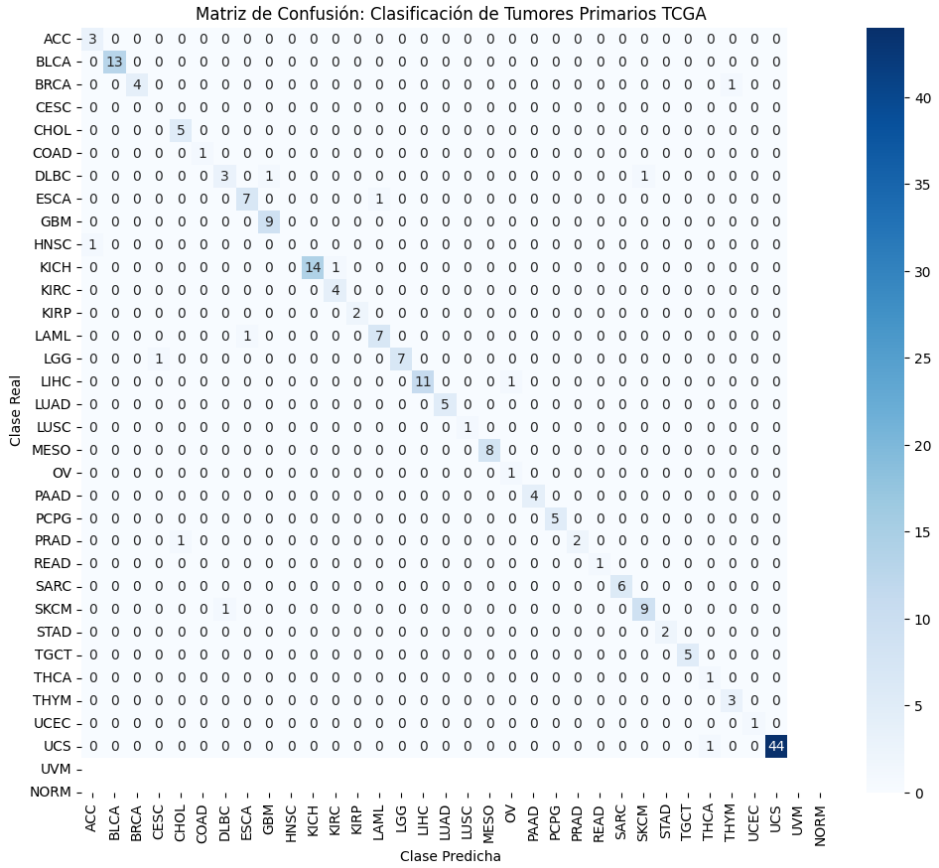
Análisis de la robustez

Evaluación en escenarios clínicos diversos:

- Buen rendimiento en cáncer metastásico y lesiones precancerosas.
- Precisión mantenida en datos externos y frente al *batch effect*.
- Capacidad para detectar etapas tempranas de cáncer.
- No afectado por la deriva epigenética asociada a la edad.

Rendimiento: batería de pruebas

- Pruebas del rendimiento del modelo en pruebas proporcionadas.
- Accuracy del 93 %
- Los resultados muestran una buena capacidad de discriminación, aunque persisten confusiones.



Rendimiento: datos sintéticos

- Generación de 200 muestras artificiales, asignadas aleatoriamente a 34 clases,
- Metilaciones son matrices de 200×24565.
- Las clases se agruparon en tres rangos con diferentes distribuciones:
  - Clases 0-9: media 4.0, desviación estándar 1.0
  - Clases 10-19: media 6.0, desviación estándar 1.5
  - Clases 20-33: media 5.0, desviación estándar 0.5
- Aunque se introdujeron diferencias entre grupos, el modelo apenas alcanzó un 3 % de precisión.

Rendimiento: datos de prueba propios

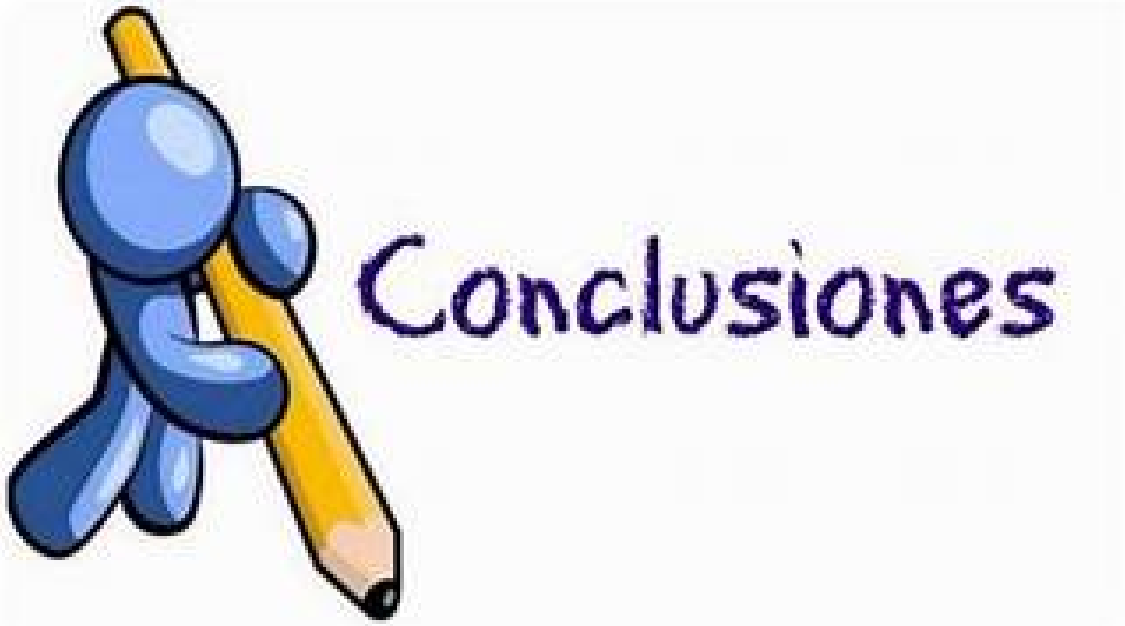
- Generación de conjunto de pruebas propio a partir de dos muestras del subtipo TCGA-BRCA
- Preprocesamiento de los datos de acuerdo a lo explicado anteriormente:
  1. Filtrado y agrupación de clústeres
  2. Ajuste dimensional: de 14181 a 24565 clústeres
  3. Vectorización y valor medio por clúster
- **Evaluación:** Ambas muestras se clasificaron erróneamente, las transformaciones introducidas y las diferencias con los datos TCGA podrían haber distorsionado los perfiles originales
- **Conclusión:** El modelo necesita adaptaciones o reentrenamiento para ser aplicable fuera de su entorno original

Indice

1. Introducción: El problema del cáncer
2. Descripción y características
   - Datos de metilación
   - Modelo Híbrido
   - Evaluación del rendimiento
3. Estructura del modelo
   - Codificador
   - Decodificador
   - Clasificador
   - Entrenamiento y prevención de fugas
4. Análisis de resultados
   - Análisis del espacio latente
   - Análisis de la robustez
   - Rendimiento y pruebas
5. Conclusiones
6. Referencias

Conclusiones

- **Rendimiento condicionado:** Nuestras propias pruebas evidencian una clara limitación en cuanto a su capacidad de generalización.
- **Dependencia del conjunto original:** Fuerte de las condiciones específicas del conjunto original.
- Se deberia enfatizar más la necesidad de adaptar el modelo para otros contextos.



Indice

1. Introducción: El problema del cáncer
2. Descripción y características
   - Datos de metilación
   - Modelo Híbrido
   - Evaluación del rendimiento
3. Estructura del modelo
   - Codificador
   - Decodificador
   - Clasificador
   - Entrenamiento y prevención de fugas
4. Análisis de resultados
   - Análisis del espacio latente
   - Análisis de la robustez
   - Rendimiento y pruebas
5. Conclusiones
6. Referencias

Referencias

- **CancerNet software:**
  https://osf.io/j6gcv/?view_only=d18c6831b9e24002937ab1028fc0d418
- **An integrative pan-cancer-wide analysis of epigenetic enzymes reveals universal patterns of epigenomic deregulation in cancer**
  https://link.springer.com/article/10.1186/s13059-015-0699-9
- **DNA methylome profiling of human tissues identifies global and tissue-specific methylation patterns**
  https://genome.cshlp.org/content/28/9/1285